

Análise de Regressão

Prof. Dr. Juliano Bortolini

Bacharelado em Estatística - UFMT

Discente:

RGA:

Prova 1

1. (1,0) Demonstre que:

$$r = \frac{1}{n-1} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s_x} \right) \left(\frac{y_i - \bar{y}}{s_y} \right) = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}},$$

em que $s_x = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}}$ e $s_y = \sqrt{\frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n-1}}$ são os desvios padrão amostrais de X e Y , respectivamente.

Resolução

Comece pela definição via *z-scores* (padronizações):

$$z_{xi} = \frac{x_i - \bar{x}}{s_x}, \quad z_{yi} = \frac{y_i - \bar{y}}{s_y},$$

e

$$r = \frac{1}{n-1} \sum_{i=1}^n z_{xi} z_{yi} = \frac{1}{n-1} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s_x} \right) \left(\frac{y_i - \bar{y}}{s_y} \right).$$

Fatorando $s_x s_y$ (que não dependem de i):

$$r = \frac{1}{n-1} \cdot \frac{1}{s_x s_y} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{(n-1) s_x s_y}.$$

Agora substitua as expressões dos desvios-padrão amostrais:

$$s_x = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}} \Rightarrow \sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} = \sqrt{n-1} s_x,$$

$$s_y = \sqrt{\frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n-1}} \Rightarrow \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2} = \sqrt{n-1} s_y.$$

Logo,

$$(n-1) s_x s_y = (\sqrt{n-1} s_x)(\sqrt{n-1} s_y) = \sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}.$$

Substituindo no quociente anterior,

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}},$$

o que prova a igualdade desejada:

$$\boxed{\frac{1}{n-1} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s_x} \right) \left(\frac{y_i - \bar{y}}{s_y} \right) = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}}$$

Conclui-se que r é a covariância amostral (com divisor $n-1$) normalizada pelo produto dos desvios-padrão amostrais.

2. **(2,0)** Demonstre que:

$$r = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2} \sqrt{\sum_{i=1}^n (Y_i - \bar{Y})^2}} = \frac{\sum_{i=1}^n X_i Y_i - \frac{(\sum_{i=1}^n X_i)(\sum_{i=1}^n Y_i)}{n}}{\sqrt{\left(\sum_{i=1}^n X_i^2 - \frac{(\sum_{i=1}^n X_i)^2}{n} \right) \left(\sum_{i=1}^n Y_i^2 - \frac{(\sum_{i=1}^n Y_i)^2}{n} \right)}}$$

em que n é o tamanho da amostra, $\sum X_i Y_i$ é o somatório dos produtos de X e Y , $\sum X_i$ e $\sum Y_i$ são os somatórios individuais de X e Y , $\sum X_i^2$ e $\sum Y_i^2$ são os somatórios dos quadrados de X e Y .

Resolução

Partimos da forma “centralizada” do coeficiente de correlação:

$$r = \frac{S_{xy}}{\sqrt{S_{xx} S_{yy}}}, \quad S_{xy} = \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y}), \quad S_{xx} = \sum_{i=1}^n (X_i - \bar{X})^2, \quad S_{yy} = \sum_{i=1}^n (Y_i - \bar{Y})^2.$$

1) Expansão do numerador S_{xy}

$$\begin{aligned} S_{xy} &= \sum_{i=1}^n [X_i Y_i - X_i \bar{Y} - \bar{X} Y_i + \bar{X} \bar{Y}] \\ &= \sum_{i=1}^n X_i Y_i - \bar{Y} \sum_{i=1}^n X_i - \bar{X} \sum_{i=1}^n Y_i + \sum_{i=1}^n \bar{X} \bar{Y} \\ &= \sum_{i=1}^n X_i Y_i - \bar{Y} (n\bar{X}) - \bar{X} (n\bar{Y}) + n\bar{X}\bar{Y} \\ &= \sum_{i=1}^n X_i Y_i - n\bar{X}\bar{Y}. \end{aligned}$$

Usando $\bar{X} = \frac{1}{n} \sum X_i$ e $\bar{Y} = \frac{1}{n} \sum Y_i$,

$$S_{xy} = \sum_{i=1}^n X_i Y_i - n \left(\frac{\sum X_i}{n} \right) \left(\frac{\sum Y_i}{n} \right) = \sum_{i=1}^n X_i Y_i - \frac{(\sum X_i)(\sum Y_i)}{n}.$$

2) Expansão dos denominadores S_{xx} e S_{yy}

Para S_{xx} :

$$\begin{aligned} S_{xx} &= \sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n (X_i^2 - 2\bar{X}X_i + \bar{X}^2) \\ &= \sum_{i=1}^n X_i^2 - 2\bar{X} \sum_{i=1}^n X_i + n\bar{X}^2 = \sum_{i=1}^n X_i^2 - 2\bar{X} (n\bar{X}) + n\bar{X}^2 \\ &= \sum_{i=1}^n X_i^2 - n\bar{X}^2 = \sum_{i=1}^n X_i^2 - \frac{(\sum_{i=1}^n X_i)^2}{n}. \end{aligned}$$

Analogamente, para S_{yy} :

$$S_{yy} = \sum_{i=1}^n Y_i^2 - n\bar{Y}^2 = \sum_{i=1}^n Y_i^2 - \frac{(\sum_{i=1}^n Y_i)^2}{n}.$$

3) Substituição em r

Substituindo as formas “não-centralizadas” em $r = S_{xy}/\sqrt{S_{xx}S_{yy}}$, obtemos

$$r = \frac{\sum_{i=1}^n X_i Y_i - \frac{(\sum_{i=1}^n X_i)(\sum_{i=1}^n Y_i)}{n}}{\sqrt{\left(\sum_{i=1}^n X_i^2 - \frac{(\sum_{i=1}^n X_i)^2}{n}\right) \left(\sum_{i=1}^n Y_i^2 - \frac{(\sum_{i=1}^n Y_i)^2}{n}\right)}},$$

que é exatamente a expressão pedida.

Observação A igualdade acima mostra a passagem da forma “centralizada” (em torno das médias) para a forma “de somatórios brutos” (útil em cálculo manual/planilhas). Em notação compacta, $S_{xy} = \sum XY - \frac{(\sum X)(\sum Y)}{n}$, $S_{xx} = \sum X^2 - \frac{(\sum X)^2}{n}$ e $S_{yy} = \sum Y^2 - \frac{(\sum Y)^2}{n}$.

3. **(1,0)** Para o teste de hipóteses $H_0 : \rho = 0$ versus $H_a : \rho \neq 0$, em que ρ é o coeficiente de correlação populacional, o teste de correlação de Pearson é baseado na estatística de teste

$$T = \frac{R\sqrt{n-2}}{\sqrt{1-R^2}}$$

que segue uma distribuição t com $n-2$ graus de liberdade. A estatística R é o coeficiente de correlação amostral.

Para um teste de hipóteses sobre a correlação, as hipóteses nula e alternativa, e a região de rejeição são dadas a seguir:

Hipótese Alternativa	Região de Rejeição para um Teste de Nível α
$H_a : \rho > 0$	$t \geq t_{\alpha, n-2}$
$H_a : \rho < 0$	$t \leq -t_{\alpha, n-2}$
$H_a : \rho \neq 0$	$t \geq t_{\alpha/2, n-2}$ ou $t \leq -t_{\alpha/2, n-2}$

O **Turbine Oil Oxidation Test (TOST)** e o **Rotating Bomb Oxidation Test (RBOT)** são dois procedimentos diferentes para avaliar a estabilidade à oxidação de óleos de turbinas a vapor. O artigo “*Dependence of Oxidation Stability of Steam Turbine Oil on Base Oil Composition*” (*J. Soc. Tribologists Lubricat. Engrs., Out.*

1997: 19–24) apresentou as seguintes observações para x = tempo do teste TOST (horas) e y = tempo do teste RBOT (minutos) em 12 amostras de óleo.

Table 2: Resultados dos testes TOST e RBOT para 4 amostras de óleo (dados adaptados).

TOST	RBOT
4200	370
3600	340
3750	375
3675	310

- a. Calcule e interprete o valor do coeficiente de correlação amostral.

```
x <- c(4200, 3600, 3750, 3675)
y <- c(370, 340, 375, 310)

Sxy <- sum((x - mean(x)) * (y - mean(y)))
Sxy
```

```
[1] 13781.25
```

```
Sxx <- sum((x - mean(x))^2)
Sxx
```

```
[1] 217968.8
```

```
Syy <- sum((y - mean(y))^2)
Syy
```

```
[1] 2718.75
```

```
r <- Sxy / sqrt(Sxx * Syy)
r
```

```
[1] 0.5661179
```

- b. Como o valor de r seria afetado se tivéssemos escolhido x = tempo RBOT e y = tempo TOST?

Não iria alterar o valor.

- c. Como o valor de r seria afetado se o tempo RBOT fosse expresso em horas?

Não iria alterar o valor.

- d. Realize um teste de hipóteses para decidir se os tempos dos testes RBOT e TOST estão linearmente relacionados.

```
n <- length(x)
R <- r
T_calc <- (R * sqrt(n - 2)) / sqrt(1 - R^2)
T_calc
```

```
[1] 0.9712337
```

```
alpha <- 0.05
t_crit <- qt(1 - alpha/2, df = n - 2)
t_crit
```

```
[1] 4.302653
```

```
abs(T_calc) > t_crit
```

```
[1] FALSE
```

4.

O aquecimento global é uma questão importante, e as emissões de CO_2 desempenham um papel fundamental nessa discussão. O artigo “*Effects of Atmospheric CO_2 Enrichment on Biomass Accumulation and Distribution in Eldarica Pine Trees*” (*J. Exp. Bot.* 1994: 345–349) descreve os resultados do crescimento de pinheiros sob diferentes níveis de CO_2 no ar.

Os dados abaixo correspondem às observações onde:

- x = concentração atmosférica de CO_2 (partes por milhão)
- y = massa em gramas após 11 meses de experimento.

Tabela. Concentração de CO_2 (x) e Massa (y)

x	408	408	554	554	680	680	812	812
y	1100	1300	1600	2500	3000	4300	4200	4700

```
x <- c(408, 408, 554, 554, 680, 680, 812, 812)
y <- c(1100, 1300, 1600, 2500, 3000, 4300, 4200, 4700)
```

a. **(0,5)** Calcule as quantidades: $\sum x_i$, $\sum y_i$, $\sum x_i^2$, $\sum y_i^2$, $\sum x_i y_i$, $\bar{x}$, $\bar{y}$, S_{xx} , S_{yy} e S_{xy} .

```
(sum_x <- sum(x))
```

```
[1] 4908
```

```
(sum_y <- sum(y))
```

```
[1] 22700
```

```
(sum_x2 <- sum(x^2))
```

```
[1] 3190248
```

```
(sum_y2 <- sum(y^2))
```

```
[1] 78930000
```

```
(sum_xy <- sum(x * y))
```

```
[1] 15441400
```

```
(n <- length(x))
```

```
[1] 8
```

```
(mean_x <- mean(x))
```

```
[1] 613.5
```

```
(mean_y <- mean(y))
```

```
[1] 2837.5
```

```
(S_xx <- sum((x - mean_x)^2))
```

```
[1] 179190
```

```
(S_yy <- sum((y - mean_y)^2))
```

```
[1] 14518750
```

```
(S_xy <- sum((x - mean_x) * (y - mean_y)))
```

```
[1] 1514950
```

b. **(0,5)** Ajuste um modelo de regressão linear simples relacionando x e y .

```
b1 <- S_xy / S_xx  
b1
```

```
[1] 8.454434
```

```
b0 <- mean_y - b1 * mean_x  
b0
```

```
[1] -2349.295
```

c. **(1,0)** Calcule os erros-padrões do coeficiente angular e do coeficiente linear.

```
SSR <- b1 * S_xy  
SSR
```

```
[1] 12808045
```



```
SST <- S_yy  
SST
```

```
[1] 14518750
```

```
SSE <- SST - SSR  
SSE
```

```
[1] 1710705
```

```
QM_res <- SSE / (n - 2)  
QM_res
```

```
[1] 285117.6
```

```
SE_b1 <- sqrt(QM_res / S_xx)  
SE_b1
```

```
[1] 1.261407
```

```
SE_b0 <- sqrt(QM_res * (1/n + mean_x^2 / S_xx))  
SE_b0
```

```
[1] 796.5671
```

d. (1,0) Calcule o intervalo de confiança de 95% para o coeficiente angular e interprete-o.

```
alpha <- 0.05  
t_crit <- qt(1 - alpha/2, df = n - 2)  
IC_b1 <- c(b1 - t_crit * SE_b1, b1 + t_crit * SE_b1)  
IC_b1
```

```
[1] 5.367883 11.540985
```

e. (1,0) Realize o teste t para o coeficiente angular. Há evidência de que a concentração de CO_2 afeta a massa dos pinheiros? Justifique sua resposta.

```
t_stat <- b1 / SE_b1  
t_stat
```

```
[1] 6.702386
```

```
t_crit <- qt(1 - alpha/2, df = n - 2)  
abs(t_stat) > t_crit
```

```
[1] TRUE
```

- f. (1,0) Encontre um intervalo de confiança de 95% para a quantidade média de massa de pinheiros quando a concentração de CO_2 é de 680 ppm.

```
x0 <- 680  
y_hat <- b0 + b1 * x0  
y_hat
```

```
[1] 3399.72
```

```
SE_y_hat <- sqrt(QM_res * (1/n + (x0 - mean_x)^2 / S_xx))  
SE_y_hat
```

```
[1] 206.5821
```

```
IC_y_hat <- c(y_hat - t_crit * SE_y_hat, y_hat + t_crit * SE_y_hat)  
IC_y_hat
```

```
[1] 2894.232 3905.208
```

- g. (1,0) Encontre um intervalo de predição de 95% para a quantidade média de massa de pinheiros quando a concentração de CO_2 é de 600 ppm.

```
x0_pred <- 600  
y_hat_pred <- b0 + b1 * x0_pred  
y_hat_pred
```

```
[1] 2723.365
```

```
SE_y_hat_pred <- sqrt(QM_res * (1 + 1/n + (x0_pred - mean_x)^2 / S_xx))  
SE_y_hat_pred
```

```
[1] 566.6103
```

```
IC_y_hat_pred <- c(y_hat_pred - t_crit * SE_y_hat_pred, y_hat_pred + t_crit * SE_y_hat_pred)  
IC_y_hat_pred
```

```
[1] 1336.920 4109.811
```

[@profjulianobortolini](#) www.julianobortolini.com.br [linkedin](#) [github](#) [lattes](#)