

Análise de Regressão

Prof. Dr. Juliano Bortolini

Bacharelado em Estatística - UFMT

Discente:

RGA:

Prova 1

1. **(2,0)** Encontre o estimador de mínimos quadrados para o parâmetro β_1 do modelo de regressão linear simples sem intercepto (regressão pela origem): $Y_i = \beta_1 X_i + \varepsilon_i$, onde $\varepsilon_i \sim \text{i.i.d. } N(0, \sigma^2)$, $i = 1, 2, \dots, n$. Mostre todos os passos do desenvolvimento matemático.
2. O aquecimento global é uma questão importante, e as emissões de CO_2 desempenham um papel fundamental nessa discussão. O artigo “*Effects of Atmospheric CO_2 Enrichment on Biomass Accumulation and Distribution in Eldarica Pine Trees*” (*J. Exp. Bot.* 1994: 345–349) descreve os resultados do crescimento de pinheiros sob diferentes níveis de CO_2 no ar.

Os dados abaixo correspondem às observações onde:

- x = concentração atmosférica de CO_2 (partes por milhão)
- y = massa em gramas após 11 meses de experimento.

Tabela. Concentração de CO_2 (x) e Massa (y)

x	408	408	554	554	680	680	812	812
y	1100	1300	1600	2500	3000	4300	4200	4700

```
x <- c(408, 408, 554, 554, 680, 680, 812, 812)
y <- c(1100, 1300, 1600, 2500, 3000, 4300, 4200, 4700)
```

- a. **(1,0)** Calcule e interprete o valor do coeficiente de correlação amostral.

```
cor(x,y)
```

```
[1] 0.9392405
```

- b. **(1,0)** Realize o teste de hipóteses para decidir se a concentração de CO_2 e a massa dos pinheiros estão linearmente relacionadas e interprete os resultados, considere $\alpha = 0,05$.

```
cor.test(x,y)
```

Pearson's product-moment correlation

```
data:  x and y
t = 6.7024, df = 6, p-value = 0.0005355
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 0.6936940 0.9892025
sample estimates:
      cor
0.9392405
```

- c. **(1,0)** Calcule o intervalo de confiança de 95% para o coeficiente de correlação amostral e interprete-o.

```
cor.test(x,y)
```

Pearson's product-moment correlation

```
data:  x and y
t = 6.7024, df = 6, p-value = 0.0005355
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 0.6936940 0.9892025
sample estimates:
      cor
0.9392405
```

- d. **(1,0)** Ajuste um modelo de regressão linear simples relacionando x e y e interprete o coeficiente linear (β_1).

```
modelo <- lm(y ~ x)
modelo
```

```
Call:
lm(formula = y ~ x)
```

```
Coefficients:
(Intercept)          x
-2349.295         8.454
```

- e. **(1,0)** Realize a análise de variância (ANOVA) para o modelo ajustado e interprete os resultados, considere $\alpha = 0,05$.

```
anova(modelo)
```

Analysis of Variance Table

```
Response: y
      Df  Sum Sq Mean Sq F value    Pr(>F)
x       1 12808045 12808045  44.922 0.0005355 ***
Residuals  6  1710705   285118
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
# a diferença entre os valores do cálculo no R e "na mão" é por causa das aproximações.
```

- f. **(0,5)** Realize o teste de hipóteses $H_0 : \beta_0 = 0$ versus $H_1 : \beta_0 \neq 0$, considere $\alpha = 0,05$.

```
summary(modelo)
```

```
Call:
lm(formula = y ~ x)
```

```
Residuals:
      Min       1Q   Median       3Q      Max
-734.46 -336.71   82.71  188.19  900.28
```

```
Coefficients:
```

```

              Estimate Std. Error t value Pr(>|t|)
(Intercept) -2349.295    796.567  -2.949 0.025637 *
x              8.454      1.261   6.702 0.000536 ***
---

```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 534 on 6 degrees of freedom

Multiple R-squared: 0.8822, Adjusted R-squared: 0.8625

F-statistic: 44.92 on 1 and 6 DF, p-value: 0.0005355

g. (0,5) Realize o teste de hipóteses $H_0 : \beta_1 = 0$ versus $H_1 : \beta_1 \neq 0$, considere $\alpha = 0,05$.

```
summary(modelo)
```

Call:

```
lm(formula = y ~ x)
```

Residuals:

```

      Min       1Q   Median       3Q      Max
-734.46 -336.71   82.71  188.19  900.28

```

Coefficients:

```

              Estimate Std. Error t value Pr(>|t|)
(Intercept) -2349.295    796.567  -2.949 0.025637 *
x              8.454      1.261   6.702 0.000536 ***
---

```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 534 on 6 degrees of freedom

Multiple R-squared: 0.8822, Adjusted R-squared: 0.8625

F-statistic: 44.92 on 1 and 6 DF, p-value: 0.0005355

h. (0,5) Realize o teste de hipóteses $H_0 : \beta_1 = 8$ versus $H_1 : \beta_1 \neq 8$, considere $\alpha = 0,05$.

```

beta1 <- 8.454
beta1_h0 <- 8
ep_beta1 <- 1.261
tc <- (beta1 - beta1_h0) / ep_beta1
tc # t calculado

```

```
[1] 0.3600317
```

```
ttab <- qt(0.975, df = 6)
ttab # t tabelado ou valor crítico.
```

```
[1] 2.446912
```

```
abs(tc) > ttab # qual é a decisão? Rej ou nao H0?
```

```
[1] FALSE
```

i. **(0,5)** Calcule o intervalo de confiança de 95% para o coeficiente linear (β_1) e interprete-o.

```
confint(modelo, level = 0.95)
```

```

                2.5 %      97.5 %
(Intercept) -4298.424521 -400.16580
x              5.367883   11.54098
```

3. **(1,0)** Considere um conjunto de dados com n observações, representado por pares ordenados (x_i, y_i) , $i = 1, 2, \dots, n$. As médias amostrais de x e y são, respectivamente, $\bar{x}$ e $\bar{y}$.

O coeficiente angular β_1 da reta de regressão linear simples de Y sobre X é dado por:

$$b_1 = \frac{S_{xy}}{S_{xx}},$$

em que: $S_{xy} = \sum (x_i - \bar{x})(y_i - \bar{y})$, $S_{xx} = \sum (x_i - \bar{x})^2$ e $S_{yy} = \sum (y_i - \bar{y})^2$.

O coeficiente de correlação de Pearson é:

$$r = \frac{S_{xy}}{\sqrt{S_{xx} \cdot S_{yy}}}$$

Os desvios padrão amostrais de X e Y são:

$$s_x = \sqrt{\frac{S_{xx}}{n-1}}, \quad \text{e} \quad s_y = \sqrt{\frac{S_{yy}}{n-1}}.$$

Demonstre que:

a.

$$\beta_1 = r \sqrt{\frac{S_{yy}}{S_{xx}}}$$

b.

$$\beta_1 = r \frac{s_y}{s_x}$$